ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KĨ THUẬT MÁY TÍNH



CO5085 - Học sâu và ứng dụng trong thị giác máy tính

Báo cáo bài tập lớn CO5085

So sánh CNN (ResNet-50) và Transformer (ViT-B/16) trên tập dữ liệu Food-101

Giảng viên: Lê Thành Sách; Nguyễn Quốc Minh

No.	MSSV	Họ và tên
1	2570436	Tiêu Trí Kiệt

Thành phố Hồ Chí Minh, 2026

Contents

1 EDA / Dataset **1**

1.1 Food-101 1

1.2 Split Dataset 1

2 DataLoader & augmentation **1**

2.1 DataLoader 1

2.2 Augmentation 2

3 Protocol thí nghiệm **3**

4 Kết quả thực nghiệm **3**

5 Thảo luận **5**

6 Appendix **8**

References **9**

1 EDA / Dataset

1.1 Food-101

Food-101 [1] là một dataset về hình ảnh của các món ăn chuyên dùng cho các bài toán nhận diện và phân loại (food image recognition), được giới thiệu lần đầu tiên vào năm 2014 bởi các nhà nghiên cứu tại Viện Công nghệ Liên bang Thụy Sĩ (ETH Zurich).

Các hình ảnh trong tập dữ liệu này được thu thập từ nền tảng mạng xã hội ẩm thực nổi tiếng lúc đó là Foodspotting.com. Vì là ảnh do người dùng thực tế chụp khi đi ăn uống, tập dữ liệu này có độ biến động rất cao về góc độ, ánh sáng và bối cảnh.

Bộ dữ liệu này bao gồm **101.000 hình ảnh** về **101 loại món ăn** phổ biến khác nhau từ bánh pizza, ramen, sushi, apple pie, gà rán,... tương đương với 101 lớp (hay nhãn) phân loại khác nhau.

Với mỗi lớp phân loại – tức với mỗi loại món ăn, có đúng **1.000 hình ảnh**, trong đó bao gồm:

- **750 ảnh cho tập train**: được cố tình giữ nguyên "nhiễu" từ thực tế như sai nhãn, màu sắc quá đà, dính đạo cụ hoặc góc chụp không chuẩn,... để thử thách khả năng thích ứng của các mô hình học máy và học sâu.
- **250 ảnh cho tập test**: được rà soát và làm sạch thủ công để đánh giá chính xác hiệu suất của mô hình.

Đồng thời, tập dữ liệu Food-101 này còn có một số đặc điểm như sau:

- Toàn bộ là ảnh màu, RGB nên số kênh `channels=3`.
- Kích thước ảnh thay đổi, cạnh dài tối đa là 512px, không phải kích thước cố định như một số tập dữ liệu khác như cố định ở 28×28 hoặc 32×32.

Do đó, tập dữ liệu Food-101 có thể được xem là một tập dữ liệu "đủ lớn" về các khía cạnh khác nhau, không chỉ lớn về kích thước ảnh, độ phân giải, số lượng lớp phân loại dẫn tới số lượng ảnh của toàn bộ tập dữ liệu, mà còn ảnh hưởng bởi tính chất của ảnh, sự đa dạng và độ chi tiết trong các ảnh đủ để có thể ảnh hưởng đến quá trình huấn luyện, thời gian và kết quả đầu ra của các mô hình.

1.2 Split Dataset

Tập dữ liệu Food-101 có tính cân bằng giữa các lớp, mỗi lớp phân loại đều có 1.000 hình ảnh và được chia thành 750 ảnh train, 250 ảnh test.

Vì thế, khi xây dựng mô hình cho bộ phân loại ảnh bằng CNN hoặc Transformer cũng sẽ giữ nguyên tính chất này. Trong đó, trong số 750 ảnh thuộc tập train, sẽ được chia thành hai tập nhỏ là tập training và tập validation với tỉ lệ 8:2, tương ứng với 600 ảnh cho tập training và 150 ảnh cho tập validation.

Bảng 1. Số lượng các tập trong Food-101

Tập	Số ảnh mỗi lớp	Tổng cộng	Mục đích
Training	600	60.600	Cập nhật gradient, học ra trọng số
Validation	150	15.150	Để chọn ra siêu tham số, learning rate, checkpoint
Test	250	25.250	Để đánh giá

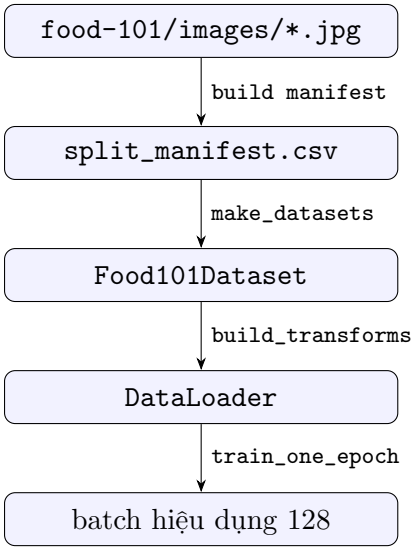
2 DataLoader & augmentation

2.1 DataLoader

Vì dataset Food-101 này có kích thước khá lớn (tổng cộng khoảng ~5GB), nên cũng giống như hầu hết các dataset trong computer vision khác, đều không thể hoặc khó có thể load lên hết trong một lần để xử lý được.

Nên sẽ áp dụng chiến thuật load **một "lô" – batch gồm 32 ảnh** một lúc để cùng xử lý trong lúc train, validation hoặc cả lúc test.

Luồng dữ liệu đi qua 4 tầng:



Hình 1. Luồng dữ liệu sơ bộ trong pipeline

Cụ thể:

- **Train**: 60.600/32 = 1.893,75, nên một epoch có 1.894 batch, batch cuối chỉ có 24 ảnh.
  - Gom 4 batch thành 1 step: $1.894 = 473 \times 4 + 2$, nên một epoch có **474 optimizer step**.
  - Nhóm cuối chỉ có 2 batch = 32 + 24 = **56 ảnh**. Loss của nhóm này được chia cho 56, không chia cho 128.
- **Val**: 15.150/32 = 473,4375, tức là có 474 batch.
- **Test**: 25.250 ảnh, dùng batch 64 để chạy nhanh hơn; batch size không ảnh hưởng kết quả vì đây là pha suy luận.

2.2 Augmentation

Bảng 2. Các phép biến đổi ảnh cho từng tập

	Train	**Val/Test**
Không gian	`RandomResizedCrop(224, scale=(0.8, 1.0), ratio=(3/4, 4/3))` + `RandomHorizontalFlip(0.5)`	`Resize(256)` (cạnh ngắn) → `CenterCrop(224)`
Nội suy	Bilinear + antialias	Bilinear + antialias
Chuẩn hoá	uint8 → $[0, 1]$ → mean/std ImageNet	như train

- Crop với scale từ 0.8 trở lên luôn giữ hơn 80% diện tích ảnh, nhờ vậy các cấu hình được so sánh công bằng: không cấu hình nào được lợi riêng từ augmentation.
- BatchNorm chỉ thấy 32 ảnh mỗi lần, gradient accumulation làm tăng batch hiệu dụng cho optimizer lên 128, nhưng thống kê BatchNorm vẫn tính trên từng batch 32.

3 Protocol thí nghiệm

Bảng 3. Danh sách cấu hình

#	Mô hình	Khởi tạo	Freeze
1	ResNet-50	scratch	full train
2	ResNet-50	pretrained	full fine-tune
3	ViT-B/16	pretrained	full fine-tune
4	ResNet-50	pretrained	freeze backbone (head-only)
5	ResNet-50	pretrained	freeze một phần

So với danh sách cấu hình được đưa ra ở phần kế hoạch Protocol, Bảng 3 đã đề cập đến 8 cách chạy thí nghiệm tương ứng với 8 cấu hình khác nhau, bảng danh sách cấu hình thực tế sẽ ít hơn 3 protocol, cụ thể:

1. ViT-B/16 from-scratch
2. ViT-B/16 pretrained được freeze một phần
3. ViT-B/16 pretrained được freeze backbone

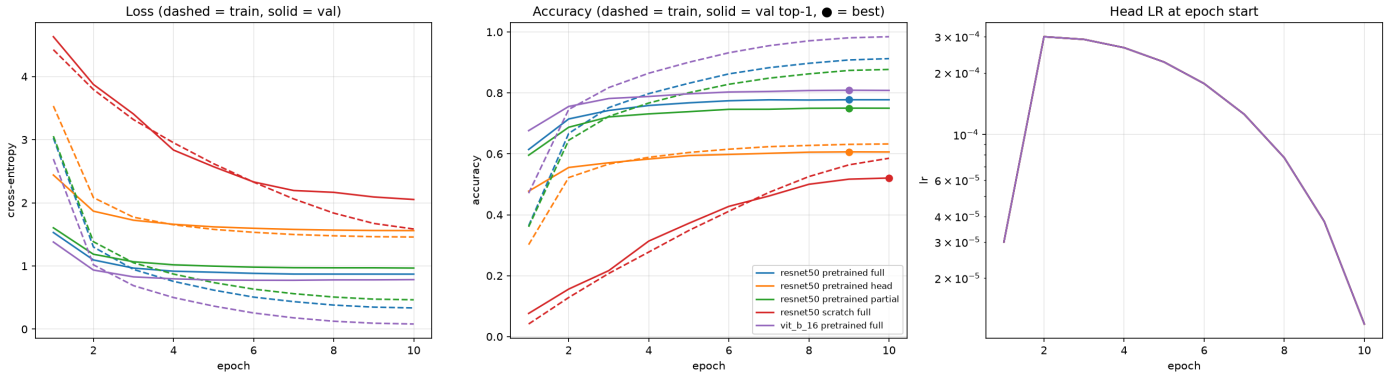
Bảng 4. Chi tiết thông tin của từng cấu hình

#	Cấu hình	Trọng số khởi tạo	Phần được train	Tham số train / tổng	LR head / backbone	Bộ nhớ đỉnh
1	ResNet scratch full	Ngẫu nhiên	Toàn bộ	23,71M / 23,71M (100%)	3e-4 / 3e-4	∼4,5 GB
2	ResNet pretrained full	`IMAGENET1K_V1` (76,1% top-1 ImageNet)	Toàn bộ	23,71M / 23,71M (100%)	3e-4 / 3e-5	∼4,5 GB
3	ViT-B/16 pretrained full	`IMAGENET1K_V1` (81,1%)	Toàn bộ	85,88M / 85,88M (100%)	3e-4 / 3e-5	∼5,6 GB
4	ResNet pretrained head	`IMAGENET1K_V1`	Chỉ `fc`	0,21M / 23,71M (0,9%)	3e-4 / –	thấp hơn full
5	ResNet pretrained partial	`IMAGENET1K_V1`	`layer4` + `fc`	15,17M / 23,71M (64%)	3e-4 / 3e-5	thấp hơn full

4 Kết quả thực nghiệm

Bảng 5. Kết quả diễn biến từng epoch (val top-1). * Best epoch

Epoch	ResNet Scratch	ResNet full	ResNet Head	ResNet Partial	ViT full
1	0,076	0,614	0,477	0,595	**0,676**
2	0,156	0,714	0,555	0,687	0,756
3	0,217	0,742	0,571	0,721	0,782
5	0,372	0,767	0,594	0,738	0,797
7	0,462	0,777	0,602	0,746	0,805
9	0,517	**0,7775***	**0,606***	**0,750***	**0,809***
10	**0,521***	0,777	0,606	0,750	0,808



Hình 2. Đường cong học qua 10 epoch

- **Pipeline huấn luyện chạy đúng**: learning rate đầu mỗi epoch đúng như thiết kế: epoch 1 bắt đầu ở 3e-5, epoch 2 lên 3e-4, sau đó giảm dần theo cosine về 1.2e-5 ở đầu epoch 10.
- Các cấu hình pretrained (bao gồm: ResNet full fine-tune, ResNet freeze backbone, ResNet freeze partial và ViT full fine-tune): phần lớn mức tăng diễn ra trong 3–4 epoch đầu, từ epoch 7 trở đi, val chỉ tăng $\leq 0{,}3$ điểm. Do đó, việc train 10 epoch được xem là đủ.
- Mức độ overfit, đo bằng khoảng cách train acc – val top-1 ở epoch 10:

Bảng 6. Khoảng cách train acc – val top-1 ở epoch 10

Cấu hình	Train acc	Val top-1	Gap
ResNet scratch	0,585	0,521	6,4
ResNet pretrained full	0,913	0,777	13,6
ResNet freeze backbone	0,632	0,606	2,6
ResNet freeze partial	0,877	0,750	12,7
ViT pretrained full	**0,984**	**0,808**	**17,6**

Qua đó, ta có thể thấy được:

- ViT pretrained full fine-tune gần như thuộc lòng tập train, val loss chạm đáy ở epoch 7, rồi tăng lại trong khi val top-1 vẫn đi ngang.
- ResNet đóng băng một phần và ResNet pretrained full fine-tune thì overfit vừa phải khi đường train có dấu hiệu đi xuống trong khi val có dấu hiệu đi lên.
- Cấu hình ResNet đóng băng backbone bị underfit, chỉ có phần head được học nên năng lực của mô hình có giới hạn.
- Cuối cùng, ResNet from-scratch có thể chưa học hết dữ liệu do chỉ có 10 epoch.

Bảng 7. Thời gian thực hiện train toàn bộ cấu hình

Cấu hình	Train/epoch thực tế	Ước tính	Val/epoch
Head	∼420 s (7,0 phút)	8,05 phút	∼105 s
Partial	∼547 s (9,1 phút)	10,2 phút	∼105 s
ResNet full	∼1.280 s (21,3 phút)	22,5 phút	∼105 s
ViT full	∼2.975 s (49,6 phút)	50,1 phút	∼205 s
Scratch	∼1.305 s	22,5 phút	∼106 s

Tổng thực tế **19,98h**; ước tính 20,6h; sai số khoảng 3%.

Bảng 8. Bảng tổng hợp kết quả đo lường từ kết quả thử nghiệm

Cấu hình	Tham số train	Val top-1	Test top-1	Test top-5	Macro-F1	Train (h)	Bộ nhớ (MB)
ViT-B/16 pretrained full	85,88M	0,809	**0,859**	0,969	0,859	8,26	7.645
ResNet-50 pretrained full	23,71M	0,778	0,828	0,961	0,828	3,55	7.415
ResNet-50 pretrained partial	15,17M	0,750	0,802	0,952	0,801	1,52	2.228
ResNet-50 pretrained head	0,21M	0,606	0,655	0,884	0,652	**1,17**	**1.203**
ResNet-50 scratch full	23,71M	0,521	0,577	0,833	0,573	3,66	7.418

- Khi so sánh giữa các cấu hình, cấu hình Transformer dùng ViT-B/16 so với ResNet-50 (pretrained full) thì Transformer tốt hơn, nhưng tốn hơn 2,3 lần thời gian train và có hơn 3,6 lần tham số.
- Pretrained full so với pretrained bị đóng băng một phần tiêu tốn khoảng hơn 2,3 lần thời gian do train thêm layer 1, layer 2 và layer 3, nhưng chỉ thêm được khoảng 2,7 điểm.
- Kết quả test top-1 so với val top-1 đều thường cao hơn 5 điểm ở mọi cấu hình, có thể do cách xây dựng dataset:
  - Tập test được làm sạch thủ công.
  - Trong khi tập train vẫn để lại nhiều nhiễu.
  - Tập val được tách ra từ tập train.

Bảng 9. Bảng so sánh McNemar theo cặp trên 25.250 ảnh test

Cặp so sánh	Cả hai đúng	Chỉ bên trái đúng	Chỉ bên phải đúng	Cả hai sai
ResNet full vs ViT full	19.650	1.265	2.046	2.289
Scratch vs pretrained full	13.846	732	7.069	3.603
Head vs full	15.816	730	5.099	3.605
Partial vs full	19.392	846	1.523	3.489

- ResNet đúng ở 1.265 ảnh mà ViT sai.
- Khoảng 2.289 ảnh (9%) cả hai mô hình đều sai, và trong đó 1.105 ảnh chúng đoán **cùng một lớp sai**. Các ảnh này nhiều khả năng mơ hồ thật hoặc bị gán nhãn sai.

Dựa vào confusion matrix (Hình 3) và phân tích lỗi:

- **Các lớp khó giống nhau ở mọi cấu hình:** `steak`, `pork_chop`, `apple_pie`, `filet_mignon`, `huevos_rancheros`, `ravioli`, `foie_gras`. Cấu hình tốt nhất cũng chỉ đạt khoảng 55–68% ở các lớp này.
- **Các lớp dễ:** `edamame` (99,6–100% với các cấu hình pretrained), `macarons`, `hot_and_sour_soup`, `pad_thai`. Đây là những món có hình dạng hoặc màu sắc rất đặc trưng.
- **Các cặp bị nhầm nhiều nhất xoay quanh nhóm thịt đỏ:**
  - `steak` ↔ `filet_mignon` (12–17% mỗi chiều).
  - `prime_rib` → `steak`, `pork_chop` → `steak`.
  - Ngoài ra: `tuna_tartare` ↔ `beef_tartare`, `chocolate_cake` ↔ `chocolate_mousse`, `apple_pie` ↔ `bread_pudding`.

5 Thảo luận

Qua các kết quả thực nghiệm, các số liệu và kết quả trên chỉ được thực hiện trên các thiết lập của cá nhân, không hoàn toàn là kết quả chung cho mọi thiết lập, cụ thể ở Bảng 10.

Bảng 10. Danh sách các thiết lập được dùng trong thí nghiệm

Thiết lập	**Giá trị**
Loss	Cross-entropy
Optimizer	AdamW (0.9, 0.999), eps 1e-8
Weight decay	0.01 cho ma trận/kernel; 0 cho bias, tham số norm, pos-emb, CLS
Batch	$32 \times 4 = 128$
Số epoch	10 (474 step/epoch $\rightarrow$ 4.740 step)
Lịch LR	Warmup 474 step (0,1× $\rightarrow$ 1×), sau đó cosine ($\rightarrow$ 0,01×)
Gradient clipping	1.0
Precision	FP16 autocast + GradScaler
Seed	1 seed = 42
Thiết bị	M4, MPS

Do đó, chỉ có 1 seed nên không có mean ± SD, cũng như scratch trong thí nghiệm chưa thể hội tụ có thể do số epoch huấn luyện không đủ, làm cho khoảng cách giữa mô hình from-scratch với pretrained trở nên xa hơn.

So với số lượng thí nghiệm ban đầu, bằng cách đo pilot trước khi tiến hành thực nghiệm chạy thực tế, nhận ra vấn đề về thời gian, tài nguyên và khả năng thực thi thí nghiệm từ 12 cấu hình xuống 8 cấu hình, sau đó là 5 cấu hình. Từ thời gian ước lượng khoảng 50 ngày xuống còn khoảng 20,6 giờ với 5 cấu hình, mỗi cấu hình 10 epoch.

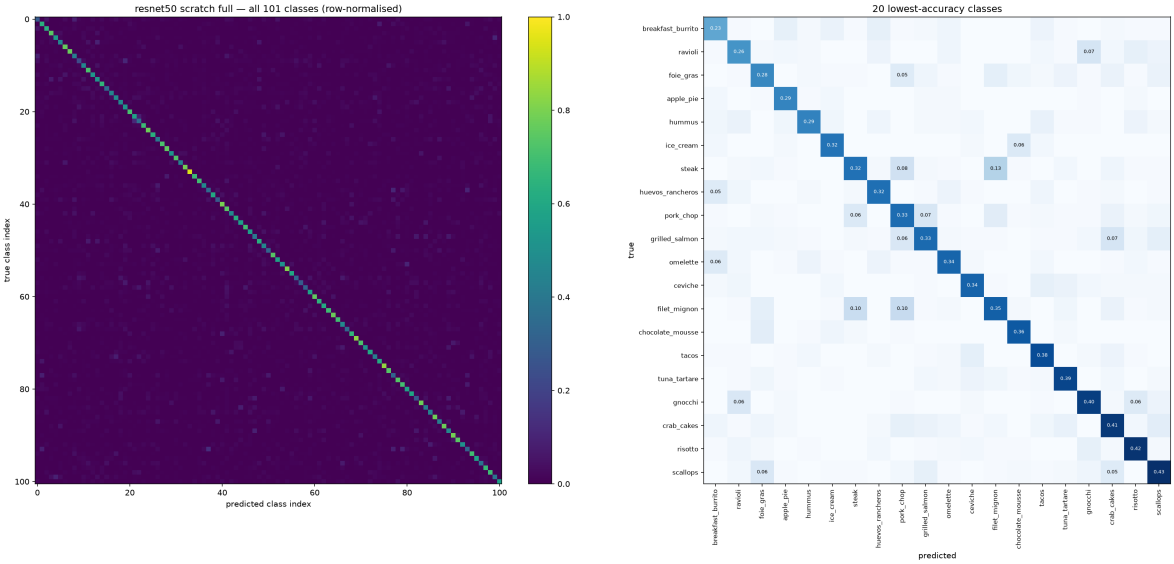
Về kết quả, dữ liệu ít thì pretraining quan trọng hơn kiến trúc, phần fine-tune quan trọng hơn số tham số được train. Partial đạt 97% kết quả của full với 43% thời gian. Lý do là `layer4` chứa đặc trưng ngữ nghĩa cấp cao, phần cần thích nghi với ảnh món ăn nhất. Ngược lại, head-only thiếu 14,6 điểm: đặc trưng ImageNet không đủ tách biệt các món ăn.

Nhiễu lỗi nằm ở dữ liệu, không ở mô hình. Val nhiễu nhưng vẫn xếp hạng đúng.

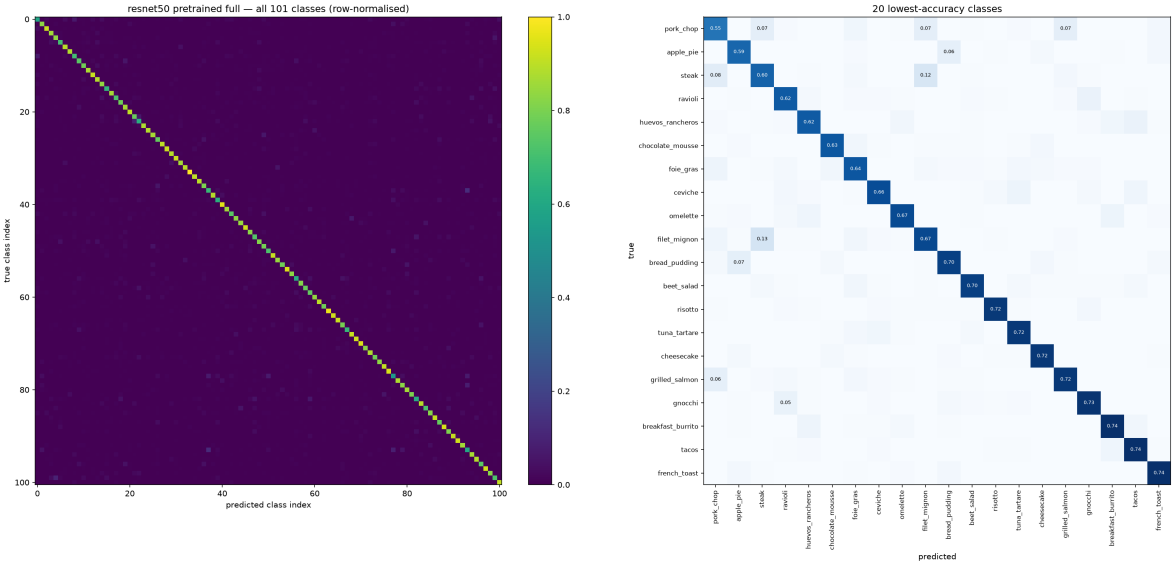
Từ đó, có thể thấy khả năng các mô hình vẫn chưa nói rõ được độ tin cậy của mình trong kết luận. Đối với các cấu hình full fine-tune có thể thêm 2 seed để có mean ± SD kiểm chứng được độ chênh lệch giữa ViT và ResNet, làm tăng độ tin cậy của kết luận hơn.

Đồng thời, tăng số lượng epoch của ResNet from-scratch lên từ 30–50 (khoảng 12 đến 20 giờ train) để quan sát điểm hội tụ của mô hình.

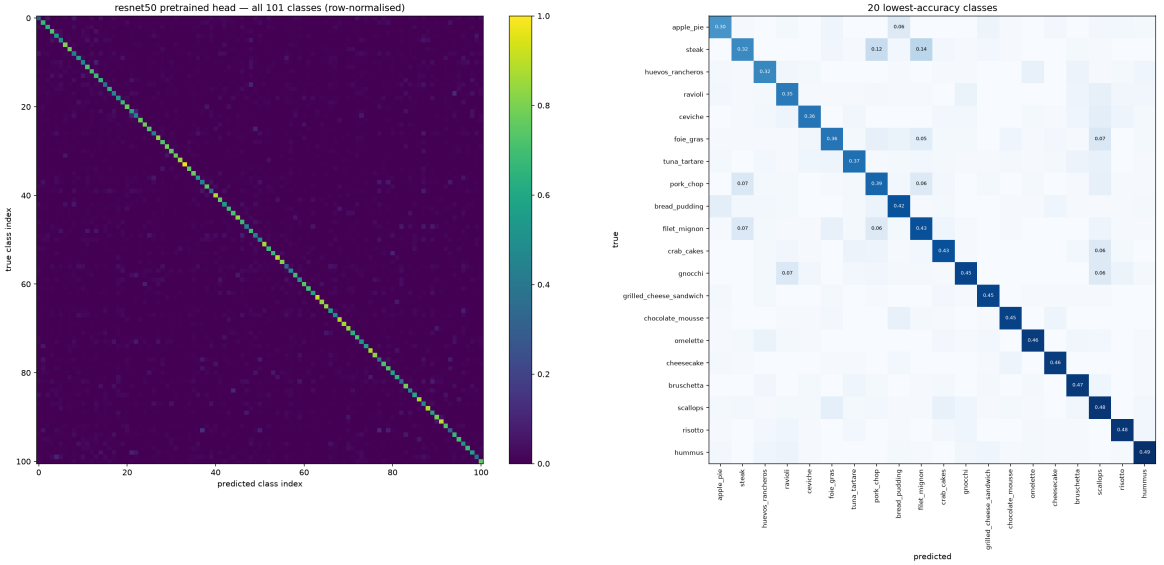
6 Appendix



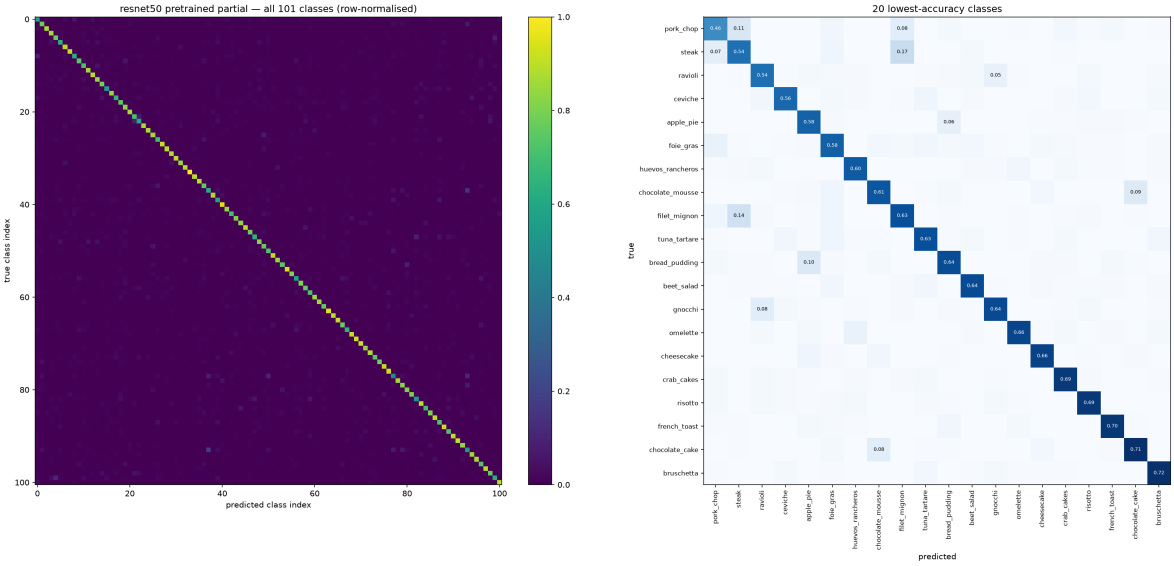
(a) CNN ResNet-50 from-scratch



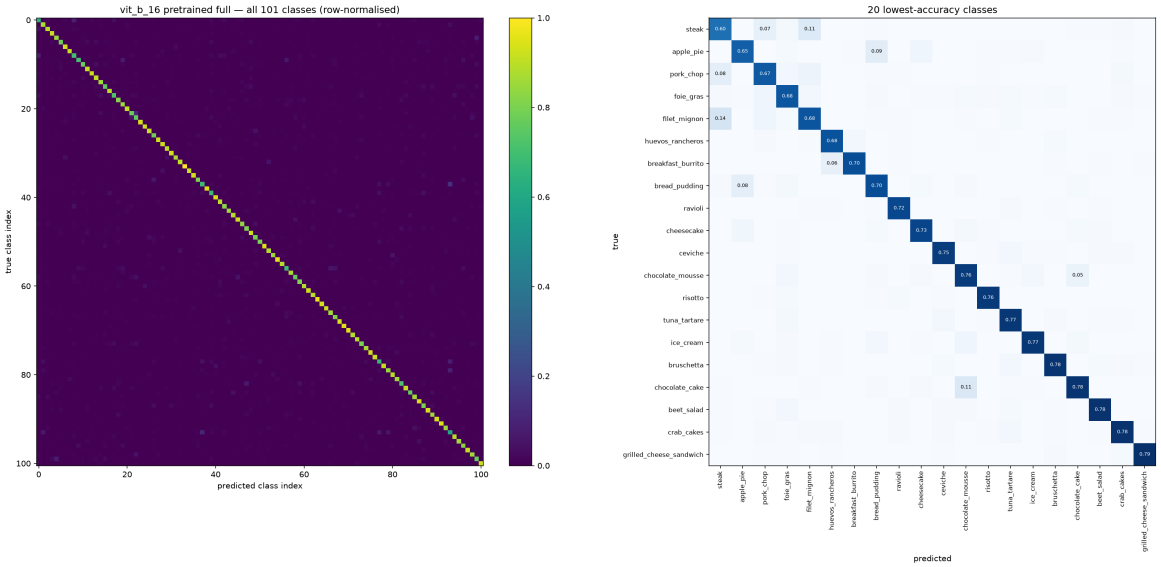
(b) CNN ResNet-50 full fine-tune



(c) CNN ResNet-50 freeze backbone



(d) CNN ResNet-50 freeze partial



(e) Transformer ViT-B/16 full fine-tune

Hình 3. Các confusion matrix của các mô hình

References

[1] *Food-101*. URL: https://data.vision.ee.ethz.ch/cvl/datasets_extra/food-101/static/bossard_eccv14_food-101.pdf.