ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KĨ THUẬT MÁY TÍNH



CO5085 - Học sâu và ứng dụng trong thị giác máy tính

Bài tập lớn A1

CNN vs Transformer trên tập ảnh lớn

A1.1 Dataset + protocol

Giảng viên: Lê Thành Sách; Nguyễn Quốc Minh

No.	MSSV	Họ và tên
1	2570436	Tiêu Trí Kiệt

Thành phố Hồ Chí Minh, 2026

Contents

1 Dataset: Food-101 **1**

2 Split Dataset **1**

3 CNN và Transformer **1**

3.1 CNN - resnet-50 1

3.2 Transformer - vit_base_patch16_224 3

4 Kế hoạch from-scratch, pre-trained và các cơ thế freeze **3**

4.1 From-scratch 3

4.2 Pre-trained 3

4.3 Freeze backbone — giữ cố định bộ trích xuất đặc trưng 3

4.4 Freeze một phần 4

4.5 Freeze finetune 4

4.6 Bảng phân phối phần sẽ chạy 4

4.7 Pipeline chung 5

References **5**

1 Dataset: Food-101

Food-101 [1] là một dataset về hình ảnh của các món ăn chuyên dùng cho các bài toán nhận diện và phân loại (food image recognition), được giới thiệu lần đầu tiên vào năm 2014 bởi các nhà nghiên cứu tại Viện Công nghệ Liên bang Thụy Sĩ (ETH Zurich).

Các hình ảnh trong tập dữ liệu này được thu thập từ nền tảng mạng xã hội ẩm thực nổi tiếng lúc đó là Foodspotting.com. Vì là ảnh do người dùng thực tế chụp khi đi ăn uống, tập dữ liệu này có độ biến động rất cao về góc độ, ánh sáng và bối cảnh.

Bộ dữ liệu này bao gồm **101,000 hình ảnh** về **101 loại món ăn** phổ biến khác nhau từ bánh pizza, ramen, sushi, apple pie, gà rán,... tương đương với 101 lớp (hay nhãn) phân loại khác nhau.

Với mỗi lớp phân loại - tức với mỗi loại món ăn, có đúng **1,000 hình ảnh**, trong đó bao gồm:

- **750 ảnh cho tập train**: được cố tình giữ nguyên "nhiễu" từ thực tế như sai nhãn, màu sắc quá đà, dính đạo cụ hoặc góc chụp không chuẩn,... để thử thách khả năng thích ứng của các mô hình học máy và học sâu.
- **250 ảnh cho tập test**: được rà soát và làm sạch thủ công để đánh giá chính xác hiệu suất của mô hình.

Đồng thời, tập dữ liệu Food-101 này còn có một số đặc điểm như sau:

- Toàn bộ là ảnh màu, RGB nên số kênh channels=3.
- Kích thước ảnh thay đổi, cạnh dài tối đa là 512px, không phải kích thước cố định như một số tập dữ liệu khác như cố định ở 28×28 hoặc 32×32.

Do đó, tập dữ liệu Food-101 có thể được xem là một tập dữ liệu "đủ lớn" về các khía cạnh khác nhau, không chỉ lớn về kích thước ảnh, độ phân giải, số lượng lớp phân loại dẫn tới số lượng ảnh của toàn bộ tập dữ liệu, mà còn ảnh hưởng bởi tính chất của ảnh, sự đa dạng và độ chi tiết trong các ảnh đủ để có thể ảnh hưởng đến quá trình huấn luyện, thời gian và kết quả đầu ra của các mô hình.

2 Split Dataset

Tập dữ liệu Food-101 có tính cân bằng giữa các lớp, mỗi lớp phân loại đều có 1,000 hình ảnh và được chia thành 750 ảnh train, 250 ảnh test.

Vì thế, khi xây dựng mô hình cho bộ phân loại ảnh bằng CNN hoặc Transformer cũng sẽ giữ nguyên tính chất này. Trong đó, trong số 750 ảnh thuộc tập train, sẽ được chia thành hai tập nhỏ là tập training và tập validation với tỉ lệ 8:2, tương ứng với 600 ảnh cho tập training và 150 ảnh cho tập validation.

Bảng 1. Thông tin số lượng của các tập dữ liệu

Tập	Số ảnh mỗi lớp	Tổng cộng	Mục đích
Training	600	60,600	Cập nhật Gradient, học ra trọng số
Validation	150	15,150	Để chọn ra siêu tham số, learning-rate, checkpoint
Test	250	25,250	Để đánh giá

3 CNN và Transformer

3.1 CNN - resnet-50

CNN sử dụng tích chập với tính cục bộ và chia sẻ trọng số, đưa một số giả định về cấu trúc ảnh vào thiết kế.

Resnet-50 [2] , là một kiến trúc mạng tích chập (convolutional neural networks) từ ResNet, được Kaiming He, Xiangyu Zhang, Shaoqing Ren, và Jian Sun của Microsoft Research giới thiệu vào 2015.

Theo giới thiệu, trong số các biến thể của ResNet (ResNet-18, Resnet-34, ResNet-50, ResNet-101, ResNet-152), thì ResNet-50 là một biến thể ở giữa được xem là mặc định của ResNet, đủ mạnh để cho một độ chính xác cao, và đủ nhỏ (khoảng 26 triệu tham số) để train và phục vụ cho thị trường.

Vấn đề chính mà ResNet giải quyết là vấn đề suy giảm hiệu suất trong các mạng neural sâu. Khi mạng neural trở nên sâu hơn, độ chính xác của chúng đạt đến mức bão hòa và sau đó giảm sút nhanh chóng. Sự suy giảm này không phải do overfitting, mà là do khó khăn trong việc tối ưu hóa quá trình huấn luyện.

Ý tưởng cảu ResNet: thay vì bắt một nhóm layer học trực tiếp ánh xạ $H(x)$, ta cho nó học phần dư (hay residual) $F(x) = H(x) - x$, rồi cộng lại đầu vào: $y = F(x) + x$.

Khối **Bottleneck Block**: ResNet-50 dùng bottleneck block gồm 3 lớp conv để tiết kiệm tính toán:

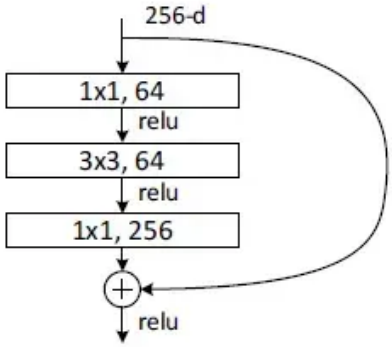


Figure 1: Fig.1. ResNet-50 bottleneck block [3]

- Lớp 1×1 đầu **giảm số kênh** (ví dụ 256 → 64), nên lớp 3×3 tốn kém chỉ phải chạy trên ít kênh.
- Lớp 1×1 cuối **mở rộng lại** (64 → 256). Hệ số mở rộng là 4.
- Khi block đầu của một stage đổi số kênh hoặc giảm kích thước, shortcut dùng **Conv 1×1 (projection)** để `x` khớp shape với `F(x)` trước khi cộng.

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
		3×3 max pool, stride 2				
conv2_x	56×56	[3×3, 64; 3×3, 64] ×2	[3×3, 64; 3×3, 64] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3
conv3_x	28×28	[3×3, 128; 3×3, 128] ×2	[3×3, 128; 3×3, 128] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×8
conv4_x	14×14	[3×3, 256; 3×3, 256] ×2	[3×3, 256; 3×3, 256] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×6	[1×1, 256; 3×3, 256; ×1, 1024] ×23	[1×1, 256; 3×3, 256; 1×1, 1024] ×36
conv5_x	7×7	[3×3, 512; 3×3, 512] ×2	[3×3, 512; 3×3, 512] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Figure 2: Fig.2. Kiến trúc tổng thể của ResNet, trong đó phần được đóng khung là ResNet-50 [3]

Quy luật chung: càng xuống sâu thì kích thước không gian **giảm một nửa** và số kênh **tăng gấp đôi**. Stage đầu học đặc trưng thấp (cạnh, màu, texture). Stage sau học đặc trưng cao (bộ phận vật thể, ngữ nghĩa).

Với Pretrained là **ImageNet-1k** và Top-1 ImageNet khoảng 76 81%.

3.2 Transformer - vit_base_patch16_224

The Vision Transformer (ViT) là một mô hình transformer encoder tương tự như BERT, được huấn luyện trên một tập các ảnh lớn có giám sát, tên là ImageNet-21k, có kích thước 224x224px. ViT chuẩn chia ảnh thành patch và dùng self-attention để học quan hệ giữa các token; mô hình này có ít thiên kiến chuyên biệt cho ảnh hơn CNN ở một số khía cạnh.

`vit_base_patch16_224` là một kiến trúc dựa trên ViT để xử lý các ảnh 224px bằng cách chia thành các "patch" 16x16 không chồng lấp nhau, với size là base gồm 12 layer, embed dim là 768, 12 heads với khoảng 86 triệu tham số.

Khối cơ bản: **Transformer Encoder Block**

Với pretrained phổ biến là **ImageNet-21k** được finetune trên 1k, và Top-1 ImageNet khoảng 81 85% tùy bộ trọng số.

4 Kế hoạch from-scratch, pre-trained và các cơ thế freeze

4.1 From-scratch

From-scratch đối với CNN và Transformer tức là vẫn dùng biến thể của CNN và Transformer được đề cập ở phần trên, tức dùng model có sẵn trong thư viện nhưng không nạp trọng số đã học từ một quá trình training trước đó, hay nói cách khác, đối với các bộ phân loại CNN và Transformer from-scratch này chỉ dùng lại mô hình trong thư viện với các trọng số được khởi tạo theo quy tắc của kiến trúc.

Trong cách dùng thông thường, from-scratch cho phép toàn bộ backbone và head học trên dataset mục tiêu, mô hình phải học cả đặc trưng ảnh lẫn cách ảnh xạ đặc trưng sang lớp.

4.2 Pre-trained

Pretrained nghĩa là nạp trọng số đã được học trước, chẳng hạn từ một tác vụ trên ImageNet, rồi sử dụng chúng cho bài toán hiện tại. Với một tập lớp mới, ta thường giữ backbone và thay head cho đúng K lớp.

4.3 Freeze backbone — giữ cố định bộ trích xuất đặc trưng

Ta có thể viết mô hình thành:

$$\hat{y} = h_\phi(f_\theta(x))$$

Trong đó:

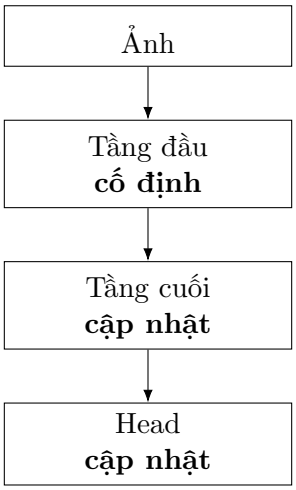
- **Backbone** f_θ: biến ảnh thành biểu diễn đặc trưng.
- **Head** h_ϕ: dùng đặc trưng đó để tạo logits cho K lớp.
- **Loss**: đo sai khác giữa logits/dự đoán và nhãn, cung cấp tín hiệu tối ưu.
- Ở CNN phân loại, backbone thường gồm các tầng tích chập; pooling gom đặc trưng trước linear head.
- Ở ViT, backbone gồm patch embedding và các Transformer block; head có thể nhận biểu diễn CLS cuối cùng.

Khi "đóng băng" backbone, chỉ head được cập nhật, tức là:

- có ít hơn tham số cần tối ưu và chi phí training thấp hơn
- giới hạn là head phải làm việc với biểu diễn cố định, dù biểu diễn đó chưa phù hợp với miền dữ liệu mới

4.4 Freeze một phần

Ví dụ giữ cố định các layer đầu, mở các layer cuối và head để học:



4.5 Freeze finetune

Tức là cập nhật toàn bộ model pre-trained, ở đây backbone pre-trained và head đều được cập nhật.

Điều này làm cho mô hình linh hoạt hơn nhưng có thể tốn thêm tài nguyên hoặc overfit.

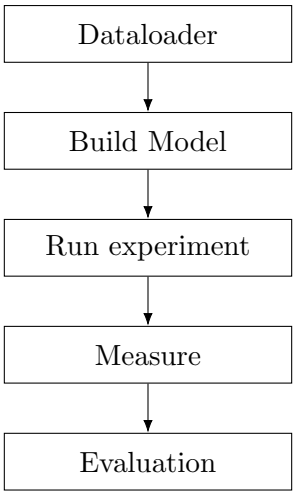
4.6 Bảng phân phối phần sẽ chạy

Bảng 2. Bảng phân phối các cách chạy thí nghiệm

Model	Không freeze	Freeze backbone	Freeze một phần	Freeze finetune
ResNet from-scratch	Toàn bộ	—	—	—
ResNet pre-trained	—	FC	layer3, layer 4, FC	toàn bộ
ViT from-scratch	Toàn bộ	—	—	—
ViT pre-trained	—	head	block, norm, head	Toàn bộ

Qua đó, có tổng cộng khoảng 8 thí nghiệm được chạy với 8 cấu hình (CONFIG) khác nhau, nhưng sẽ có chung một pipeline, dùng cùng dataset và cách split dataset.

4.7 Pipeline chung



Trong đó:

- **Dataloader:** là bước dùng để load tập dữ liệu, chia tập dữ liệu theo một cách xác định đã được trình bày ở phần trước. Đồng thời normalized theo theo trọng số mean/std của pretrained.
- **Build Model:** sẽ là bước quan trọng nhất bao gồm việc truyền vào các tham số cần thiết để tạo ra model from-scratch hoặc model pre-trained từ các trọng số đã được học, hoặc áp dụng freeze với cơ chế nào.
- **Xây dựng training loop:** là bước xây dựng cách chạy một thí nghiệm trên một model cho trước với tập train và tập val được truyền vào, cùng với criterion là CrossEntropy, optimizer là Adam,... để chạy, lưu lại lịch sử, best epoch, training time dùng cho việc evaluation sau này.
- **Đo lường:** với dataset là Food-101 có sự cân bằng về lớp thì accuracy là chỉ số quan trọng dùng để đánh giá mô hình. đồng thời còn đo lường epoch time, training time, best epoch,...
- **Đánh giá:** tính recall, F1-score, confusion matrix, vẽ learning curves và thực hiện phần đánh giá sau khi training.

References

[1] *Food-101*. URL: https://data.vision.ee.ethz.ch/cvl/datasets_extra/food-101/static/bossard_eccv14_food-101.pdf.

[2] *What is ResNet-50?* URL: https://roboflow.com/blog/what-is-resnet-50.

[3] *Deep Residual Learning for Image Recognition*. URL: https://arxiv.org/pdf/1512.03385.